

TEST PRAKTYCZNY

liczba punktów: 30

Zadanie 1 [3 pkt]

Niech X_1 oznacza zmienną losową o rozkładzie jednostajnym na przedziale $[1, 13]$, tzn. $X_1 \sim \text{Unif}([1, 13])$. Zmienna losowa X_2 ma rozkład normalny oraz tę samą wartość oczekiwaną i wariancję co zmienna losowa X_1 . Wyznacz:

- parametry dla rozkładu zmiennej losowej X_2
- $P(X_1 < 7)$, $P(X_2 < 7)$. Czy te prawdopodobieństwa są równe? Wyjaśnij dlaczego.

Dodatkowo, wstaw znak mniejszości, większości lub równości pomiędzy $P(X_1 < 0)$ oraz $P(X_2 < 0)$.

Zadanie 2 [4pkt]

Losujemy niezależnie 100 liczb z pewnego rozkładu o skończonej wartości oczekiwanej i wariancji. Stwierdź prawdziwość bądź fałszywość poniższych stwierdzeń oraz dodaj krótkie uzasadnienie lub ewentualnie powołaj się na odpowiedni fakt/twierdzenie.

- Jeżeli skośność tych danych jest bliska 0, to mam istotne statystycznie podstawy, że dane pochodzą z rozkładu normalnego.
- Jeżeli skośność tych danych jest bliska 1, to mam istotne statystycznie podstawy, że dane nie pochodzą z rozkładu normalnego.
- Jeżeli policzę średnią z tych liczb to będzie ona zbliżona do wartości oczekiwanej dla tego rozkładu.
- Możliwe są następujące relacje: średnia tych liczb jest dwa razy większa od mediany **oraz** równocześnie dominanta tych danych jest dwa razy większa od średniej.

Zadanie 3 [3pkt]

Zmienna losowa X opisuje liczbę owadów wpadających w pułapkę świetlną w ciągu jednej nocy. Ustalono, że ma ona rozkład Poissona z parametrem $\lambda = 10$. Odpowiedz na poniższe pytania. Wynik zapisz w postaci liczby lub formuły którą można bezpośrednio obliczyć w R.

- Jakie jest prawdopodobieństwo, że danej nocy w pułapkę świetlną wpadnie dokładnie 8 owadów?
- Jakie jest prawdopodobieństwo, że danej nocy w pułapkę świetlną wpadnie co najmniej 8 owadów?
- Ile wynosi drugi moment zwykły, tzn. EX^2 ?

Zadanie 4 [1pkt]

W Polsce, w przedziale wiekowym 20-50 lat żyje 6 mln kobiet. Ustalono, że wzrost w tej populacji może być przybliżony rozkładem normalnym $N(\mu = 166 \text{ cm}, \sigma = 14 \text{ cm})$. Podaj przybliżoną liczbę kobiet w tej grupie które mają wzrost pomiędzy 160 a 175 cm? Wynik zapisz w postaci liczby lub formuły którą można bezpośrednio obliczyć w R.

Zadanie 5 [1pkt]

Rozważmy następującą rozgrywkę:

Aby wejść do gry musimy zainwestować 5 zł. Następnie za pomocą symetrycznej kostki do gry losowana jest liczba oczek. Jeżeli wypadnie 1, 2 lub 3, to otrzymujemy 6 zł. Jeżeli wypadnie 4, to nic nie wygrywamy. W przypadku 5 i 6 oczek otrzymujemy 12 zł. Kierując się kryterium wartości oczekiwanej, czy taka gra jest dla nas opłacalna? Odpowiedź uzasadnij.

Zadanie 6 [2pkt]

Dana jest funkcja gęstości prawdopodobieństwa, opisująca pewną nieujemną zmienną losową

$$f(x) = \frac{1}{a} e^{-\frac{x}{a}}$$


Na podstawie próby 3, 5, 5, 19 podaj estymator parametru **a**. Przy wyznaczonym parametrze podaj wariancję zmiennej losowej X . Porównaj ją z wariancją z próby. Skomentuj otrzymane wyniki (w szczególności ewentualną różnicę).

Zadanie 7 [1pkt]

Pod każdym z poniższych wykresów pudełkowych wpisz przekształcenie, które należy wykonać na danych aby rozkład otrzymanych wartości upodobił się do rozkładu normalnego.

Wykorzystaj trzy funkcje z puli

$$\left\{ f(x) = x^2, f(x) = x^{-1}, f(x) = x^{\frac{1}{3}}, f(x) = x^e, f(x) = e^x, f(x) = \log x \right\}.$$



Zadanie 8 [2pkt]

Zebrano dane dotyczące ekspresji genu **MCPIP1** wśród **30 pacjentów zdrowych** oraz **30 pacjentów ze stanem zapalnym**. Z wcześniejszych badań wynikało, że w drugiej grupie może występować **wyższa ekspresja** tego genu. Postanowiono zweryfikować tę hipotezę, stosując **test t-Studenta**.

- Zapisz jak w tym przypadku wygląda hipoteza zerowa i hipoteza alternatywna.
- Otrzymano **p-value = 0.0011**. Czy są przesłanki, aby odrzucić hipotezę zerową na korzyść hipotezy alternatywnej? Co oznacza otrzymana wartość p – *value*. Zinterpretuj tę wartość.

Zadanie 9 [2pkt]

Zbudowano model regresji logistycznej, przewidujący prawdopodobieństwo wystąpienia czerniaka na podstawie cech X_1, X_2 , czyli $p = \frac{1}{1+\exp(-Z)}$, gdzie $Z = 2X_1 - 5X_2 - 3$, to model liniowy.

- Czy wg modelu osoba o profilu cech $(X_1, X_2) = (3, 4)$ powinna być zakwalifikowana do grupy chorych? Uzasadnij.
- Aby ocenić zbudowany model porównano przewidywania modelu z rzeczywistymi przynależnościami do grup dla kolejnych obserwacji.

Dane\Model	0	1
0	64	9
1	2	87

Oblicz czułość modelu.

Zadanie 10 [3pkt]

Badamy czas T do wystąpienia efektu terapeutycznego po podaniu pewnego leku. Zachowanie zmiennej losowej T opisuje funkcja przeżycia $S(t) = e^{-0.06t^2}$. Odpowiedz na poniższe pytania; wynik zapisz w postaci liczby lub formuły którą można bezpośrednio obliczyć w R.

- Jakie jest prawdopodobieństwo, że efekt terapeutyczny nastąpi pomiędzy 3 a 4 okresem?
- Ile razy prawdopodobieństwo wystąpienia efektu w chwili 4 jest większe niż wystąpienie efektu w chwili 3 (pod warunkiem, że efekt nie wystąpił wcześniej)?

Aby dokładniej opisać czas wystąpienia efektu postanowiono dodatkowo uwzględnić dawkę (zmienna X_1) oraz BMI (zmienna X_2). Z badań wynika, że wzrost dawki o 1 jednostkę powoduje 6-krotny wzrost szansy wystąpienia efektu, a wzrost BMI o 2 jednostki powoduje 5-krotny spadek szansy wystąpienia efektu. Podaj parametry β_1 oraz β_2 w modelu Coxa

$$h(t|X_1, X_2) = h_0(t)e^{\beta_1 X_1 + \beta_2 X_2}.$$

Zadanie 11 [5 pkt]

Rozważ dane dotyczące schizofrenii. Początek danych wygląda następująco:

NfkB	CD28	IFN	Dikeos.manic	Dikeos.reality.distortion	Dikeos.depression	Dikeos.disorganization	Dikeos.negative	Dikeos.sum
AG	TT	TT+AA	3	19	12	42	2	78
AG	TC+CC	AT	5	29	16	46	0	96
GG	TT	AT	7	25	11	41	0	84
AG	TT	TT+AA	8	27	13	59	3	110
GG	TT	AT	3	24	13	41	2	83
GG	TT	AT	6	26	13	43	2	90

Całość znajduje się w pliku („schizofrenia.txt”).

Dla badanej grupy osób rozważano genotyp dla trzech mutacji SNP, w trzech różnych genach (**NfkB**, **CD28** oraz **IFN**). Interesuje nas weryfikacja hipotezy, czy jest jakiś wyraźny efekt genotypu związany z intensywnością objawów schizofrenii (**Dikeos.sum**).

- Ile osób badano?
- Ile i jakie genotypy rozważano w przypadku **NfkB** oraz **CD28**? Jaka była liczebność w każdej z grup?
- W jakim zakresie znajdują się wartości zmiennej **Dikeos.sum**? Czy można przybliżyć jej rozkład używając rozkładu normalnego? Uzasadnij. Jeżeli tak, to dokonaj estymacji jego parametrów.
- Narysuj wykresy interakcji dla **Dikeos.sum** względem **CD28** oraz **NfkB** (przerysuj wykresy na tę kartkę, wystarczy generalny kształt). Na ich podstawie stwierdź czy zachodzi interakcja.
- Następnie utwórz dwa modele liniowe:
 - zmienna **Dikeos.sum** modelowana za pomocą **NfkB** oraz **CD28** przy czym zakładamy **model addytywny**. Ile wynosi R^2 tego modelu?
 - zmienna **Dikeos.sum** modelowana za pomocą **NfkB** oraz **CD28** przy czym zakładamy **model z interakcją**. Ile wynosi R^2 tego modelu?
- Skomentuj istotność statystyczną wyestymowanych parametrów dla **NfkB GG** w obu modelach. Z czego może wynikać ta różnica?
- Wykonaj **test anova** celem porównania utworzonych modeli. Który z modeli wydaje się lepszy? Skomentuj otrzymane wyniki.

Zadanie 12 [3 pkt]

W badaniu laboratoryjnym analizowano wpływ nowego związku chemicznego X, który prawdopodobnie hamuje procesy naprawy DNA, na częstość występowania pęknięć dwuniciowych (DSB) w DNA komórek. Celem eksperymentu było określenie, czy zastosowanie związku X w różnych stężeniach prowadzi do zwiększenia liczby pęknięć DNA oraz czy efekt ten zależy od dawki i innych czynników biologicznych.

Do badania wykorzystano dwie linie komórkowe: A i B. Komórki zostały losowo przypisane do jednej z czterech grup eksperymentalnych: grupa kontrolna (bez związku), grupa z dawką niską ($1\text{ }\mu\text{M}$), dawką średnią ($10\text{ }\mu\text{M}$) i dawką wysoką ($100\text{ }\mu\text{M}$). Dodatkowo, w niektórych próbkach zastosowano stres oksydacyjny (oznaczono jako "tak" lub "nie"). Po 24 godzinach od ekspozycji zmierzono liczbę pęknięć DSB w jądrze komórkowym w każdej próbce (każda próbka to średnia z 100 jąder).

Całość danych znajduje się w pliku („pekniecie.txt”).

Na podstawie danych zbuduj **model regresji Poissona**, w którym zmienną zależną **jest liczba pęknięć DNA**. Uwzględnij jako predyktory: **dawkę związku** (jako zmienną ciągłą), **linię komórkową** oraz obecność **stresu oksydacyjnego**.

a) Zapisz **postać** modelu z wyestymowanymi parametrami – podaj jawną formułę. Które zmienne są istotne statystycznie? Napisz krótki komentarz do tych wyników.

b) Jaka wg tego modelu jest **średnia liczba pęknięć DNA** w linii komórkowej A, przy dawce $20\text{ }\mu\text{M}$ gdzie stres oksydacyjny jest obecny.

c) Ile razy średnia liczba pęknięć DNA wzrośnie, jeżeli dawka leku X wzrośnie o $0.5\text{ }\mu\text{M}$?